

FIAP ON

ARQUITETANDO O UNIVERSO BIG DATA DA MELHORES COMPRAS

**Luis: RM565324**

**Adeilson: RM566282**

# ARQUITETANDO O UNIVERSO BIG DATA DA MELHORES COMPRAS

## SUMÁRIO

### Sumário

2 desafio(s) enfrentado(s) pela melhores compras .....	4
2.1 Contextualização do Problema.....	4
3 Planejamento das atividades.....	5
4 origem dos dados .....	6
4.1 Panorama geral das fontes de dados.....	6
4.2 Justificativas das Fontes de Dados .....	6
4.3 Detalhamento das fontes de dados .....	7
5 Arquitetura de Solução Big Data / Pipeline de Dados .....	8
5.1 Desenho da Arquitetura .....	8
5.2 Justificativa da Arquitetura .....	9
5.3 Detalhamento da Arquitetura .....	9

## 2 desafio(s) enfrentado(s) pela melhores compras

### 2.1 Contextualização do Problema

O problema escolhido foi o 3 - Diminuição da taxa de conversão (usuário anônimo para cliente) – em razão de que se caracteriza como um dos principais desafios das empresas atualmente. Em um cenário de mercado altamente competitivo e com custos de aquisição de tráfego (via anúncios digitais) cada vez mais elevados, a capacidade de transformar um visitante em um cliente pagador não é apenas um indicador de performance, mas uma questão de sustentabilidade financeira.

Para diagnosticar e reverter essa tendência, a conexão com Big Data é direta e essencial. É preciso analisar os dados de comportamento de milhões de usuários para encontrar a verdadeira causa da baixa conversão, algo que só essa tecnologia permite.

### 3 Planejamento das atividades

Projeto Análise de Conversão - Melhores Compras

Backlog

- Configurar pipeline de streaming com Kafka para os logs de navegação do site (Clickstream)
- Estruturar o armazenamento no Data Lake (HDFS) em camadas (Raw, Processed)
- Desenvolver job Spark em batch para processar e cruzar dados, criando o funil de conversão
- Criar os dashboards no Power BI com os KPIs de conversão (funil, análise por canal, etc.)
- Desenvolver Prova de Conceito

+ Add a card

Em Andamento

- Mapeamento e solicitação de acesso às fontes de dados (Kafka, Oracle DBs)
- Desenvolver pipelines de ingestão com Swoop para os bancos de dados relacionais (CRM, Produtos)

+ Add a card

Concluído

- Documentação do Projeto

+ Add a card

Inbox Plan

<https://trello.com/invite/b/68e4851d7d7d4725ed666b4b/ATTIdae74bf7d017fa3838c6c35dd0d5432cBAFE48FF/projeto-analise-de-conversao-melhores-compras>

## 4 origem dos dados

Para realizar um diagnóstico preciso sobre a queda na taxa de conversão, foram selecionadas quatro fontes de dados primárias. Elas nos permitirão cruzar informações de marketing, comportamento de navegação e dados cadastrais, fornecendo uma visão completa da jornada do usuário.

### 4.1 Panorama geral das fontes de dados

Origem	Formato	Velocidade	Volume	Horário Coleta	Localização	Proprietário
Logs de Navegação (Clickstream)	JSON	Streaming (Real-time)	Alto (Milhões de eventos/dia)	Contínuo	Servidores Web da Aplicação	Equipe de E-commerce
BD de Campanhas de Marketing	Tabela (CSV/API)	Batch (Diário)	Médio (Milhares de registros/dia)	Diariamente às 02:00	Plataformas (Google/Meta Ads)	Equipe de Marketing
BD de Clientes (CRM)	Tabela (SQL)	Batch (Diário)	Médio (Novos clientes/dia)	Diariamente às 23:00	Banco Oracle (On-premise)	Equipe de Vendas
BD de Produtos	Tabela (SQL)	Batch (Diário)	Baixo (Atualizações pontuais)	Diariamente às 23:30	Banco Oracle (On-premise)	Equipe de Produto (P&D)

### 4.2 Justificativas das Fontes de Dados

- Logs de Navegação (Clickstream): Essencial para mapear a jornada do usuário passo a passo e descobrir os pontos exatos do site onde eles desistem da compra.
- BD de Campanhas de Marketing: Serve para medir a eficiência dos anúncios, identificando quais campanhas atraem visitantes que realmente compram e quais apenas geram tráfego de baixa qualidade.
- BD de Clientes (CRM): Usado como base de comparação para entender o perfil e o comportamento de um "cliente de sucesso", contrastando com os visitantes que não convertem.

## ARQUITETANDO O UNIVERSO BIG DATA DA MELHORES COMPRAS

- BD de Produtos: Permite investigar se a baixa conversão é um problema geral ou se está concentrada em produtos ou categorias específicas do site.

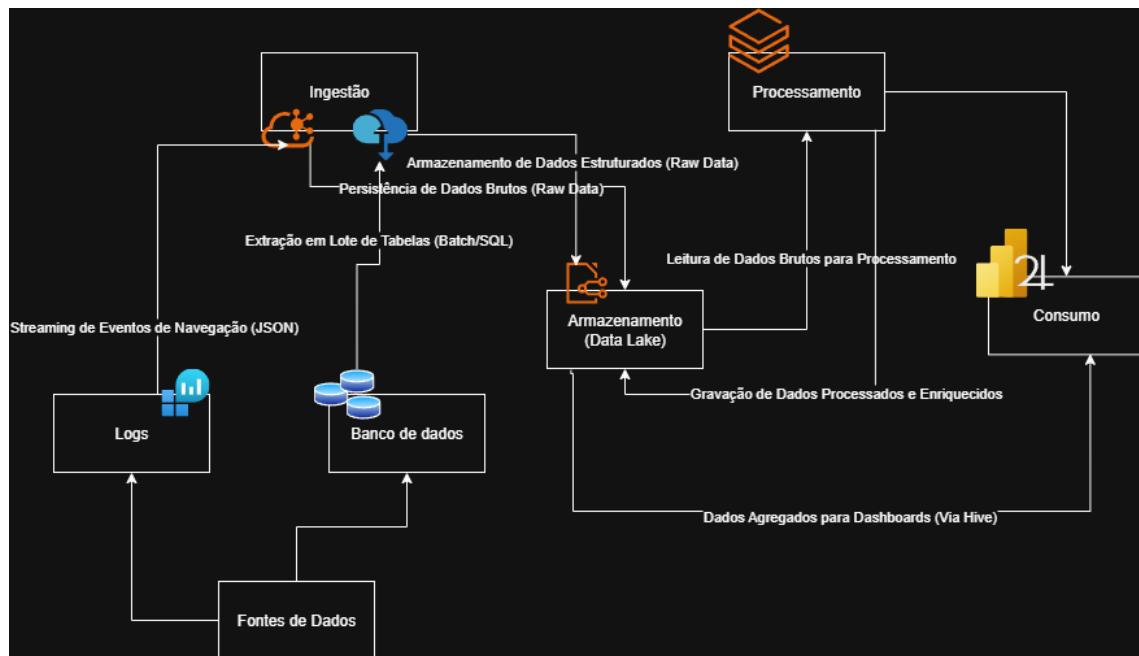
### 4.3 Detalhamento das fontes de dados

Tabela	Apelido	Descrição	Interessados	Dono da informação	Retenção
T_PRODUTO	Prod	Armazena todos os dados cadastrais e de inventário dos produtos comercializados pela "Melhores Compras".	Marketing, Vendas, Logística, BI	Diretor de Produto (P&D)	Produtos são mantidos por até 2 anos após a última venda. Backup diário.

Coluna	Tipo de Dado	Descrição	Exemplo
ID_PRODUTO	NUMBER(10)	Identificador único e sequencial para cada produto. Chave primária.	837492
NM_PRODUTO	VARCHAR2(255)	Nome comercial do produto exibido no site.	Smart TV LED 50" 4K Samsung
DS_CATEGORIA	VARCHAR2(100)	Categoria principal à qual o produto pertence.	Eletrônicos
VL_PRECO_ATUAL	NUMBER(10,2)	Preço de venda atual do produto em Reais (R\$).	2199.90
QT_ESTOQUE	NUMBER(5)	Quantidade de unidades do produto disponíveis em estoque.	150
DT_CADASTRO	DATE	Data em que o produto foi cadastrado no sistema pela primeira vez.	05/03/2024

## 5 Arquitetura de Solução Big Data / Pipeline de Dados

### 5.1 Desenho da Arquitetura



<https://drive.google.com/file/d/1b88hmb2UuLKvpQj2dDB5jLT0H8Co63ON/view?usp=sharing>

## 5.2 Justificativa da Arquitetura

A arquitetura proposta, baseada no ecossistema open-source Apache Hadoop e Spark, foi escolhida por ser uma solução de padrão industrial que garante alta escalabilidade horizontal e baixo Custo Total de Propriedade (TCO), evitando o aprisionamento tecnológico (vendor lock-in). Tecnicamente, ela implementa um padrão Lambda simplificado, utilizando o Spark como um motor unificado para o processamento tanto em **lote (batch)**, para análises históricas de funil, quanto em **tempo real (streaming)**, para análise de eventos correntes. Essa capacidade dual, combinada com o suporte nativo do Spark para Machine Learning (MLlib), oferece uma plataforma flexível e robusta, capaz de suportar desde a construção de dashboards operacionais até futuras demandas de análise preditiva.

## 5.3 Detalhamento da Arquitetura

A arquitetura de dados opera em um fluxo contínuo, iniciando com a camada de **ingestão**, onde **Apache Kafka** captura o streaming de logs de navegação em tempo real, enquanto **Apache Sqoop** transfere em lote (batch) os dados dos bancos de dados relacionais. Todos esses dados brutos, de fontes heterogêneas, são centralizados e persistidos no **HDFS**, que atua como o Data Lake da solução. A camada de **processamento** é unificada no **Apache Spark**, cujo motor em memória executa jobs de batch para análises históricas (ETLs, funis), streaming para análises de eventos correntes e Machine Learning via biblioteca MLlib. Finalmente, na camada de **consumo**, os dados já processados são expostos para ferramentas de Business Intelligence através de uma interface SQL provida pelo **Apache Hive**, e para a análise aprofundada de cientistas de dados via **Jupyter Notebooks** utilizando a API PySpark.

## REFERÊNCIAS

**FIAP. Fase 6: Arquitetura de Big Data e Soluções Paralelas e Distribuídas.**  
São Paulo: FIAP ON, 2025. Material didático do curso de Data Science.  
Disponível em: <https://on.fiap.com.br/local/salavirtual/conteudo-digital.php>.